

**E.E. PROFESSOR ALLYRIO DE FIGUEIREDO BRASIL
DESENVOLVIMENTO DE SISTEMAS**

EDSON DA SILVA GUEDES

**NIETTETTS
SINTETIZADOR DE FALA EM PORTUGUÊS BRASILEIRO PARA HARDWARES
QUE OPERAM EM SISTEMAS OPERACIONAIS LINUX**

**GUARULHOS
2025**

Edson da Silva Guedes

NietteTTS

Desenvolvimento de sintetizador de fala em português brasileiro para hardwares que operam em sistemas operacionais *Linux* como sistemas de *Desktops* e embarcados.

Área de concentração: Computação.

Linha de pesquisa: Processamento de Fala.

E.E. Professor Allyrio de Figueiredo Brasil

Desenvolvimento de Sistemas

Orientador: Luiz Felipe Vecchietti

Coorientador: Carolina Almeida

Guarulhos - SP

2025

Edson da Silva Guedes

NietteTTS

Desenvolvimento de sintetizador de fala em português brasileiro para hardwares que operam em sistemas operacionais *Linux* como sistemas de *Desktops* e embarcados.

Área de concentração: Computação.

Linha de pesquisa: Processamento de Fala.

Monografia aprovada. Guarulhos - SP, 18 de dezembro de 2025:

Luiz Felipe Vecchietti

Orientador

Carolina Almeida

Coorientador

Convidado

Convidado

Guarulhos - SP

2025

Dedico esse trabalho e o resultante dele para meu orientador Luiz Felipe Vecchietti, que sempre esteve ao meu lado e viu potência em minha pessoa.

Agradecimentos

Agradeço a equipe FalaBrasil pela disponibilidade do corpus CETUC, ao Luiz Felipe Vecchietti pela disponibilidade corpus THLS, ao meu amigo Pedro pelo seu apoio e ao todos e todas que estiveram ao meu lado.

Resumo

Esse trabalho tem finalidade na criação de um sintetizador de voz para idioma português brasileiro para para hardwares que operam em sistemas operacionais *Linux* como sistemas de *Desktops* e embarcados. Contendo nesse trabalho os procedimentos usados, mensuração e outros aspectos do projeto

Palavras-chave: TTS, HMM, Português Brasileiro, Linux, Desktop

Abstract

This work aims to create a voice synthesizer for Brazilian Portuguese for hardware operating on Linux operating systems, such as desktop and embedded systems. This work includes the procedures used, measurements, and other aspects of the project.

Keywords: TTS, HMM, Portuguese Brazilian, Linux, Desktop

Resumen

Este trabajo tiene como objetivo crear un sintetizador de voz para portugués brasileño para hardware que funcione con sistemas operativos Linux, como sistemas de Desktop y sistemas embebidos. Este trabajo incluye los procedimientos utilizados, las mediciones y otros aspectos del proyecto.

Palabras clave: TTS, HMM, Portugués Brasileño, Linux, Desktop

Lista de ilustrações

Figura 1 – Comparação entre REAPER e SPTK (algoritmo padrão) para extração de F0 31

Índice de algoritmos

1	Versão modificada da função LTS para usar Phonetisaurus através do script feito em linguagem de programação Bash Shell (Resumida)	28
2	Script Bash Shell auxiliar da função LTS (Resumida)	29

Lista de tabelas

Tabela 1 – Exemplo de comparação de fonemas e grafemas de algumas palavras do português brasileiro	17
Tabela 2 – Exemplo de normalização de texto para algumas sentenças do português brasileiro	17
Tabela 3 – Significado das variáveis da fórmula <i>WER</i>	25
Tabela 4 – Significado das variáveis da fórmula <i>CER</i>	26
Tabela 5 – Resultados obtidos pelos modelos 1 (<i>train</i>) e 2 (<i>train+teste</i>)	26
Tabela 6 – Transcrição de algumas sentenças aleatórias feitas pelos modelos	26
Tabela 7 – Informações sobre nome das vozes e seus corpus que foram usados	30
Tabela 8 – Resultados obtidos para <i>FOMAX</i> e <i>FOMIN</i> das vozes Ana, Paula e Pieroni .	31
Tabela 9 – Valores de α para cada taxa amostragem em Khz	33
Tabela 10 – Valores de M e α para as taxas de amostragem usadas nesse trabalho	33
Tabela 11 – Valores <i>MCD</i> para cada voz desenvolvida nesse projeto	35

Lista de abreviaturas e siglas

TTS	Text-to-Speech
HMM	Hidden Markov Model
F0	Fundamental Frequency
MCEP	Mel-Cepstral Coefcients
G2P	Grapheme-to-Phoneme
HTS	HMM/DNN-based Speech Synthesis System
STR	Voicing Strengths
TCL	Tool Command Language
MCD	Mel Cepstral Distortion
DTW	Dynamic Time Warping
MOS	Mean Opinion Score
USP	Universidade de São Paulo
IPA	International Phonetic Alphabet
SSML	Speech Synthesis Markup Language
Festival CLI	Festival Command-line interface
OCR	Optical Character Recognition
CER	Character Error Rate
WER	Word Error Rate
STT	Speech-to-Text
MT	Machine Translate
BLUE	Bilingual Evaluation Understudy
CETUC	Centro de Estudos em Telecomunicações
NFFT	Non-Uniform Fast Fourier Transform
SPTK	Speech Signal Processing Tools

FST	Finite-State Transducers
LTS	Letter to Sound
CART	Classification And Regression Trees

Sumário

1	INTRODUÇÃO	15
1.1	Motivação	15
1.2	Objetivos	15
2	VISÃO GERAL	16
2.1	Sistemas operacionais baseado em Linux	16
2.2	Sistema Text-to-Speech	16
2.2.1	Fonética Básica	16
2.2.1.1	Diferenças entre fonema e grafema	17
2.2.2	Normalização de Textual	17
2.2.3	G2P	18
2.2.4	Técnicas de Geração de Fala	18
2.2.4.1	Unit Selection	18
2.2.4.2	Statistical Parametric Synthesis based in HMM	19
2.2.4.3	Deep Learning	19
2.3	Conceitos usados nesse trabalho	20
2.3.1	Alinhamento Fonético (Alinhamento Fonético Temporal)	20
2.3.2	Frequência Fundamental	20
2.3.3	MCEP	20
2.4	Ferramentas que vão ser usadas no projeto	20
2.4.1	Festival Speech Synthesis System	21
2.4.2	Festvox	21
2.4.3	REAPER	21
2.4.4	SPTK-4	21
2.4.5	Phonetisaurus	21
3	DESENVOLVIMENTO	23
3.1	Construção do Suporte do Português Brasileiro ao Festival	23
3.1.1	Fonemas escolhido para esse trabalho	23
3.1.1.1	Projeto <i>WikiPron</i>	23
3.1.2	Construção do Phoneset	24
3.1.3	Modelo G2P	24
3.1.3.1	Comparação com método de treinamento do Festival e Phonetisaurus	24
3.1.3.2	Construção de Modelo G2P	25
3.1.3.2.1	Mensuração de Modelo G2P	25
3.1.3.2.2	Métricas usadas para Mensuração de Modelo G2P	25

3.1.3.3	Implementação de Phonetisaurus ao Festival	27
3.2	Construção das Vozes	29
3.2.1	Corpus usados para as vozes	29
3.2.1.1	CETUC	29
3.2.1.2	THLS	30
3.2.2	Organização dos Corpus	30
3.2.3	Construção de Modelo Vocal	30
3.2.3.1	Extração de F0 usando REAPER	30
3.2.3.2	Extração de MCEP	32
3.2.3.3	Extração de STR (Voicing Strengths)	33
3.2.3.4	Combinação de F0, MCEP, STR em ccoefs.	34
3.2.4	Mensuração de Modelos	34
3.2.4.1	Escala MCD	35
3.2.4.2	Escala MOS	35
3.3	Implementação em Speech-Dispatcher	36
3.3.1	Modificação da extensão	36
4	CONSIDERAÇÕES FINAIS	38
	REFERÊNCIAS	39

1 Introdução

1.1 Motivação

Desenvolvimento de sintetizador de fala em português brasileiro para hardwares que operam em sistemas operacionais *Linux* como sistemas de *Desktops* e embarcados. Oferecendo síntese de fala de baixo recursos computacionais e com pouco espaço de armazenamento.

1.2 Objetivos

- 1) Construção de sintetizador de fala para sistemas operacionais *Linux*;
- 2) Síntese de fala em português brasileiro a partir das técnicas desenvolvidas nesse trabalho.

2 Visão Geral

Visão geral dos conceitos abordados nesse trabalho, como a definição de sistemas operacionais *Linux* e seus hardwares, a estrutura genérica de um sintetizador de fala, técnicas de geração de síntese, conceitos base usados e ferramentas usadas.

2.1 Sistemas operacionais baseado em Linux

Linux, é um tipo de núcleo (interface hardware a software) desenvolvido na abordagem de código-aberto. Por senso comum, *Linux* é conhecido como sistema operacional apesar dessa afirmação não é verdadeira (BONFIM,). É bastante usado em diversos sistemas operacionais como núcleo como interface dos seus softwares com hardwares onde são executados. Gerenciando processos, *CPU*, *GPU*, memória, funções e componentes do hardware (KERNEL. . . ,). Esse trabalho se destina a sistemas operacionais que utilizam núcleo *Linux* com foco no público comum como sistemas para uso *desktops* e *laptops*. E para uso em sistemas que rodam em embarcados como *Orange Pi*, *Raspberry Pi*, *Allwinner* em cenários que utilizam funções de síntese de fala como assistentes virtuais, chamados de clientes e servidores que utilizam para disponibilidade de serviços *Web*. O desenvolvimento desse trabalho destinou a sistemas operacionais baseados em *Debian*, como *Ubuntu*, *Zorin OS*, *Pop OS*, *Linux Mint* e ao próprio *Debian*.

2.2 Sistema Text-to-Speech

Esses sistemas tem a finalidade de transformar um texto escrito em ondas sonoras (JURAFSKY; MARTIN, , p. 348). Usados em diversos sistemas que necessitam feedback falado como *softwares* de acessibilidade, sistemas de atendimento ao cliente, narrações e entre outros. Em um sistema *TTS*, é composto em normalização textual, transcrição fonética e geração de fala.

2.2.1 Fonética Básica

A fala humana é composta por sons que resultam quase todos da ação de certos órgãos sobre a corrente de ar vinda de nossos pulmões. Sendo esses conjunto de órgãos sendo chamado de aparelho fonador, os quais são compostas pelos seguintes órgãos: pulmões, brônquios, traqueia, laringe onde está as cordas vocais e cavidades supralaríngeas (faringe, boca e fossas nasais) (CUNHA; CINTRA, 2008).

2.2.1.1 Diferenças entre fonema e grafema

Os fonemas são os sons da fala humanas transcritos, os grafemas são representações ortográficas desses sons presente na escritas das palavras. Há um engano em pensar que grafemas e fonemas são iguais, devido que a algumas línguas como, por exemplo, o espanhol e português são dependentes da ortografia para haver uma pronúncia “correta” da palavra. Mas, somente é senso comum derivado da característica dessas linguagens.

Tabela 1 – Exemplo de comparação de fonemas e grafemas de algumas palavras do português brasileiro

Palavra	Grafemas	Transcrição Fónetica
meu	m e u	m e w
amor	a m o r	a m o ɹ
minha	m i n h a	m i ɲ a
noiva	n o i v a	n o j v e

Fonte: Transcrições de palavras retiradas do projeto WikiPron, em `data/scrape/tsv/por_latn_bz_broad_filtered.tsv`.

2.2.2 Normalização de Textual

Em sistemas *TTS*, é necessário normalizar o texto fornecido para serem lidos corretamente. A normalização textual normalizar os elementos textual em sua forma escrita por extenso como números, siglas, abreviações e outros elementos textuais. Alguns elementos possam sofrer alterações em sua pronúncia de acordo com seu contexto como o caso algumas siglas que possam ser lidas letra por letra como *IPA* (I P A) ou lidar como uma palavra como *USP* (USP), os números podem sofrer com essa mudança de pronúncia como uso dos numerais 1 e 2 que podem ser pronúncia caso são acompanhadas de uma palavra flexionada no gênero feminino ou masculino (CASELI; NUNES, , p. 41) ou em caso números tem que ser lidos pelo seus algarismos como números de telefone ou senhas (JURAFSKY; MARTIN, , p. 349), números acompanhados com sua unidade de medida e entre outros.

Tabela 2 – Exemplo de normalização de texto para algumas sentenças do português brasileiro

Sentença	Após a Normalização
1ªPessoa a ganhar o campeonato de xadrex em SP.	primeira pessoa a ganhar o campeonato de xadrex em são paulo
Nessa semana terá uma média de 40ºGraus de temperatura.	nessa semana terá uma média de quarenta graus de temperatura
No dia 01/04 é o dia da mentira.	no dia primeiro de abril é o dia da mentira
50% de carga.	cinquenta por centro de carga

Sentença	Após a Normalização
Fonte: Sentenças digitados pelo próprio autor do documento.	

2.2.3 G2P

É responsável de transcrever o texto normalizado em sua forma fonética, representado em fonemas. A transcrição pode ser feita através de um dicionário fonético (léxico) que contém as fonemas corresponde da palavra, através de um modelo previamente treinado a partir de um léxico ou uso mistro (SOUZA, , p. 8). Usando o léxico e utilizando o modelo para transcrever as palavras que não estão no léxico como o caso de nomes e estrangeirismo.

Existem várias técnicas para tarefa de transcrição fonética como uso de regras, modelos de aprendizagem de máquina como árvores de decisão, *n-gramas*, *FST* e baseadas em *deep learning*. Apesar que os modelos criadas usando técnicas de *deep learning* e aprendizagem de máquina possam oferecer resultados mais precisos em comparação com a utilização de regras devido a necessidade de um léxico que tenham a cobertura suficiente para todas as variações de pronúncia do idioma alvo.

2.2.4 Técnicas de Geração de Fala

É responsável por transformar as informações do pós-processamento da etapa de transcrição fonética em sinais sonoros. Previamente sendo treinando com essas informações retiradas de um *dataset* para relaciona-las, para assim gerar a síntese. Várias técnicas forma desenvolvidas ao longo do tempo, com as principais sendo *Unit Selection*, *Statistical Parametric using HMM*, e *Deep Learning*.

2.2.4.1 Unit Selection

Unit ou Seleção de Unidades, consiste em gerar síntese a partir de áudios gravados do *dataset*, tendo esse mesmo armazenados. Fazendo a decomposição do texto em diversas unidades (*units*), sendo essas unidades fonemas, di-fonema, palavras ou mesmo uma várias de acordo com a variação do *Unit Selection*, *Hybird Unit Selection* que suas unidades são de varios tipos diferente no mesmo modelo. O treinamento é feito usando um processamento do *dataset* e descomposto nas unidades alvo acompanhadas com suas informações de contexto, como informações prosódicas, linguísticas e seus arquivos de onda de origem. Modelando um modelo que recebe a unidade alvo e suas informações para selecionar melhor “pedaço” de forma de onda do *dataset* para o contexto desejado. Por fim, é executando um pós-processamento para suaviza a forma de onda gerada para que possar mascarar os cortes feitos (ruídos) A qualidade de síntese é proporcional ao *dataset* escolhido, tendo em vista que o *dataset* dever ser rico ou balanceado o suficiente para o contexto de uso escolhido. Como uma cobertura dos contextos fonéticos da língua alvo com sua variações de tom ou mesmo em um tom neutro para economizar pro-

cessamento e armazenando. Mesmo atendendo esses critérios, a síntese possa ser inferior em comparação com a síntese feita pelo locutor(a) devido a limitações da própria técnica de *Unit Selection* com suas técnicas de concatenação e suavização de forma de onda.

2.2.4.2 Statistical Parametric Synthesis based in HMM

Statistical Parametric Synthesis based Hidden Models Markov ou Síntese Estática Paramétrica baseada em Modelos Ocultos de Markov, consiste na geração de fala usando modelos estáticos para modelagem da fala através de parâmetros. Extraindo informações sonoras como frequência fundamental (tom), espectro (timbre) e duração de cada unidade para treinar modelos para prever essas mesmas informações e passadas ao *vocoder* para sua unificação e posteriormente a sua onda sonora gerada (BLACK, e). Os modelos feitos usando essa técnica tem um tamanho de armazenando preferentemente pequeno em comparação com os modelos treinados usando as técnicas de *Unit Selection* e *Deep Learning*. Pois, apenas armazenam as informações necessárias (parâmetros) para gerar a síntese, tendo modelos genéricos médios para cada fonema (unidade) para geração de fala. Para treinamento de um sintetizador de fala usando essa técnica, é necessário que o dataset tenha as informações básicas da língua alvo com as suas unidades sonoras (fonemas). Um *dataset* de 1h de duração contendo frases balanceadas foneticamente de um locutor possa ser suficientes, apesar não obter uma síntese de boa qualidade, obterá uma síntese capaz de gerar forma de onda básica para língua alvo. As desvantagens dessa técnica em comparação com as técnicas de síntese usando *Deep Learning* ou mesmo usando *Unit Selection* é sua baixa similaridade ou mesmo decaimento da similaridade do locutor original que foi feito o treinamento. Devido a influência do *vocoder*, a natureza da modelagem de fala usando *HMM* que apenas armazenar modelos medianos para cada fonema ou mesmo como foi feito o treinamento (incluído tamanho do *dataset*, diversidade sonora ou mesmo como foi feito a extração das informações sonoras). Essa técnica era bastante usada antes do surgimento das técnicas usando *Deep Learning*, em softwares sintetizadores de fala como *HTS* (Modificação do Software de Reconhecimento de Fala usando *HMM*, para geração de fala) e outros softwares proprietários.

2.2.4.3 Deep Learning

Atualmente usasse técnicas baseada em redes neurais com aprendizagem profundo (*Deep Learning*), que aprendem através dos próprios arquivos de onda forma sem nenhuma parametrização. Variando em suas técnicas de aprendizagem e *vocoder* e em sua extração de informações dos arquivos de onda. Usando varios *frameworks* (*TensorFlow*, *Pytorch* entre outros), para varias tarefas focadas na síntese, como normalização textual, transcrição fonética e no próprio *vocoder*.

Para esse trabalho, foi escolhido a técnica *Statistical Parametric Synthesis based in HMM*, devido ao software escolhido que será desenvolvido o sintetizador de fala suporta apenas

as técnicas *Statistical Parametric Synthesis based in HMM* e *Unit Selection* e há familiaridade com sua documentação.

2.3 Conceitos usados nesse trabalho

Nesse tópico, terá explicação para os conceitos fundamentais que serão abordados na etapa de desenvolvimento.

2.3.1 Alinhamento Fonético (Alinhamento Fonético Temporal)

Consiste em alinhar os arquivos de forma de onda com suas transcrições fonéticas, com as fonemas e suas marcações de tempo. Isso é fundamental na técnica de *Statistical Parametric Synthesis*, para rotulagem das fonemas com suas respectivas informações acústicas e suas estimações de tempo.

2.3.2 Frequência Fundamental

Frequência Fundamental ou $F0$, é frequência de uma onda sonora medida em Hz e em taxa de amostragem (*Sample Rate*) é em KHz (1 KHz para cada 1000Hz). A frequência fundamental é aplicado a voz e a síntese sendo a percepção de tom. Em síntese de fala, a cada fonema em um dado contexto terá uma frequência fundamental específica, sendo esse valor de frequência predicado pelo modelo que foi treinado com essas informações.

2.3.3 MCEP

MCEP, é uma variação do espectrograma na escala mel, que consiste é obter os coeficientes principais da forma de onda. O espectrograma tem muitas informações uteis, mas tem informações que não serão processadas, devido a alto consumo de desempenho para processamento do espectrograma. Vários processos são feito para obter os coeficientes necesarios para obter a síntese, *MCEP* com suas informações e suas característica está descritos em (BäCKSTRÖM et al.,).

2.4 Ferramentas que vão ser usadas no projeto

Aqui conterà informações referentes das ferramentas usadas nesse trabalho, desde as usadas para extração das informações dos arquivos de forma de onda e as quais que foram usadas para construção do sintetizador de fala.

2.4.1 Festival Speech Synthesis System

Festival Speech Synthesis System, ou como *Festival TTS*, é um *framework* de fala feito pelo *The Centre for Speech Technology Research (CSTR)* em tradução livre Centro para Pesquisas para Tecnologia da Fala que consiste construir sistemas de sínteses de fala ou sintetizadores de fala (FESTIVAL,).

2.4.2 Festvox

Festvox é um kit para desenvolvimento para construção de vozes para *Festival TTS*, contendo scripts para etapas da construção de um sintetizador para *Festival TTS*. Como a extração de *MCEP*, *F0*, alinhamento fonético temporal e a construção de modelos de sínteses de fala para as técnicas de *Statistical Parametric Synthesis* e *Unit Selection* (BLACK, c).

Para esse trabalho, foi feito diversas modificações com finalidade de obter melhores resultados na sínteses como na etapa de extração de *F0*, *MCEP* e modelagem de modelo para treinamento do sintetizador.

2.4.3 REAPER

REAPER é um software de linha de comando para extração de *F0* usando algoritmo do mesmo nome de arquivos de forma de onda (TALKIN,). Foi escolhido devido que a síntese feita usando *REAPER* para extração de *F0* ofereceu melhores resultados na percepção de tom e intensidade sonora usando método tradicional do projeto *Festvox*.

2.4.4 SPTK-4

SPTK4 ou *SPTK* é um kit de ferramentas de linha de comando destinadas a processamento de fala como extração de *F0*, *MFCC*, espectrograma, mel espectrograma, conversão de tipos de dados e entre outros (YOSHIMURA et al.,). O projeto *Festvox* tem encapsulado *SPTK* da versão anterior 3.6 com modificação para extração de *STR* (Excitação Mista) baseada em *F0*. Todos os scripts que dependiam do *SPTK-3.6* foram modificados para suporta essa nova versão e nova abordagem para obter *STR* desenvolvida nesse trabalho.

2.4.5 Phonetisaurus

Phonetisaurus, é um software via linha de comando acompanhados com scripts para treinamento e uso de modelos de transcrição fonética de palavras usando a biblioteca *OpenFST*. Através de um dicionário fonético é possível treinar modelos *G2P* e usar-los para tarefas de transcrição fonética (AdolfVonKleist,). *Phonetisaurus*, foi usado para substituição da função de transcrição fonética do *Festival TTS* devido as desvantagens no treinamento do modelo usando as técnicas do Festival e problemas ao uso de acertos nas palavras.

A função de transcrição fonética do Festival, não suporta codificação *UTF-8* completamente, ocorrendo a omissão de caracteres com acertos no treinamento e uso da função. Processo de integração do *Phonetisaurus* ao *Festival TTS* será descrito nesse trabalho.

Phonetisaurus foi modificado para suporta a nova versão da biblioteca *OpenFST* (versão 1.8.4) através do *fork* (DANIJEL,), e posteriormente feito o merge da modificação feita nesse trabalho (Pallas13, c) para correção de transcrições nulas relatado em (Rita-ritally,).

3 Desenvolvimento

Esse capítulo, descreverá o processos de construção do sintetizador de fala no *Festival TTS* como processo de construção do suporte do idioma Português Brasileiro ao Festival, implementação do *Phonetisaurus* para *G2P*, corpus usados, modificações feitas no *Festvox*, avaliação de modelos de voz e implementação ao Speech Dispatcher.

3.1 Construção do Suporte do Português Brasileiro ao Festival

É necessário criar um diretório de suporte na cópia local do repositório da ferramenta *Festvox* com nome do idioma em formato *ISO 3166-1 alpha-2* a ser suportando e posteriormente qualquer modificação. Isso é fundamental para criação de novas vozes com arquivos pré-prontos para português brasileiro. Em razão disso, foi criando em **festvox/src/vox_files/** o diretório nomeado de **pt** para modificação e adição de arquivos necessários.

3.1.1 Fonemas escolhido para esse trabalho

Para fazer uma voz para uma nova língua, é necesario fornecer um mapeamento fonológico chamado *Phoneset* ((BLACK, a) que contém as características fonológicas de cada fonema usado, é necessário para construir o modelo que consiga modelar corretamente a língua usando suas próprias característica acústicas e fonológicas.

Para esse trabalho, os fonemas escolhidos pretercerem ao Alfabeto Fónetico Internacional (*IPA*) retiradas do projeto *WikiPron* (LEE et al.,).

3.1.1.1 Projeto *WikiPron*

O projeto *WikiPron* (LEE et al.,) é uma ferramenta de linha de comando para mineração de pronúncias de palavras do *Wiktionary*, tendo em seu repositório datasets feitos com pronúncias de palavras para diversos idiomas incluído suas variações dielétricas como português brasileiro (WIKIPRON/DATA/SCRAPE/TSV/POR_LATN_BZ_BROAD_FILTERED...,) e português europeu (WIKIPRON/DATA/SCRAPE/TSV/POR_LATN_PO_BROAD_FILTERED...,).

A escolha do *WikiPron* e seus conjuntos de dados de pronúncias foi devido ser melhor representação atual que apresentar pronúncias atualizadas devido ao *Wiktionary*. Sendo possível, regeneração para adicionar mais pronúncias ao conjuntos de dados disponíveis ou do idioma alvo.

3.1.2 Construção do Phoneset

Para construção do *phoneset*, foi necessário o uso do livro (CUNHA; CINTRA, 2008), para obter as características fonológicas para os fonemas. Houver a falta de informações para alguns fonemas faltantes, foi necessário pesquisas na *Wikipédia* no idioma inglês para obter melhores resultados, o *phoneset* resultante está disponível em (Pallas13, b).

3.1.3 Modelo G2P

3.1.3.1 Comparação com método de treinamento do Festival e Phonetisaurus

De acordo com (BLACK, e) e (BLACK, a), para realização de transcrições de palavras é realizado por modelos baseados em árvores de decisão. Sendo chamado de *Letter to Sound* ou Letra para Som em tradução livre. Realizando diversos processos para tratamento do dicionário fonético de entrada para realização do treinamento do modelo *G2P*. Descrito em (BLACK, b) como:

- 1) Pré-processamento do dicionário fonético em conjunto de treinamento adequado ao Festival;
- 2) Definido emparelhamento entre grafemas e fonemas;
- 3) Frequência entre os pares de grafemas e fonemas;
- 4) Extrair dados de cada grafema para treinamento individual;
- 5) Treinar modelos *CART* (Tipo de Árvores de Decisão) para predição de fonemas a partir dos fonemas;
 1. Treinar modelos para cada grafemas
 2. Unir os modelos feitos em um modelo.
- 6) Modelo *LTS* concluído.

Ao usar a função de *G2P* e treinamento de modelo usando essa técnica e implementação do *Festival TTS*, tem problemas no processamento de palavras que contêm acertos ortográficos resultado em transcrições nulas ou incorretas. Devido que *Festival TTS* foi desenvolvido com base na codificação *ISO-8889-1* e desenvolvido principalmente ao idioma inglês, em outros projetos de desenvolvimento de suporte de idiomas eram desenvolvidos utilizando essa codificação e utilizando técnica de normalização de codificação.

Foi feito o uso do *Phonetisaurus* por oferecer transcrições fonéticas para palavras que contenham acentuação ortográfica e menor custo de tempo e processamento computacional para treinamento com alta precisão, alterações foram feitas para implementação do mesmo no *Festival TTS*. Uso com *Speech-Dispatcher* foi feito modificações decorrente a essa mudança, a modificação foi documentada nesse trabalho.

3.1.3.2 Construção de Modelo G2P

Foi gerando um léxico com transcrições de palavras com hifes, siglas e abreviações descompostas a partir do modelo treinado utilizando o léxico principal, e posteriormente o léxico criado foi unificado ao léxico principal. Nesse trabalho foi treinado dois modelos, modelo 1 foi treinado utilizando a divisão do léxico em treinamento (*train*) e teste (*test*) dividindo a cada 9 linhas para treinamento e 1 para teste, e no modelo 2 foi utilizando todo o léxico (*train+test*).

3.1.3.2.1 Mensuração de Modelo G2P

Para mensuração dos modelos *G2P*, foi usando duas métricas usadas em tecnologia de fala para texto (*Speech-to-Text*) e uma usada em tecnologias de tradução de máquina (*Machine Translate*). Sendo respectivamente às métricas de *WER*, *CER* e *BLEU*.

3.1.3.2.2 Métricas usadas para Mensuração de Modelo G2P

Métrica WER A métrica *WER*, se destinasse a mensuração de precisão de um sistema *STT*, quantificar a diferença da transcrição original para uma transcrição gerada pelo sistema *STT*. Considerando essas seguintes categorias de erro: Substituições, Deleções e Inserções de palavras (DataMListic, b).

$$\frac{S + D + I}{N}$$

Tabela 3 – Significado das variáveis da fórmula *WER*

Variável	Significado
S	Substituições
D	Deleções
I	Inserções
N	Total de Palavras da Transcrição Original

Fonte: Word Error Rate (WER) Explained - Measuring the performance of speech recognition systems (DataMListic, b).

Métrica CER

A métrica *CER* é similar a métrica *WER*, mas modificada para caracteres incluído letras acentuadas, espaços em branco e qualquer outra modificação a nível de caracteres. Usada principalmente para mensuração de precisão de sistemas *OCR* em tradução livre Reconhecimento Óptico de Caracteres, mas existe a aplicação em sistemas *STT*.

$$\frac{S + D + I}{N}$$

Tabela 4 – Significado das variáveis da fórmula *CER*

Variável	Significado
S	Substituições
D	Deleções
I	Inserções
N	Total de Caracteres da Transcrição Original

Fonte: Word Error Rate (WER) Explained - Measuring the performance of speech recognition systems (DataMListic, b), adaptado para CER.

Métrica BLUE

A métrica *BLUE* é usada em sistemas de *MT*, em tradução livre Substituto de Mensuração Bilíngue responsável por avaliar a aproximação de uma feita pelo sistema *MT* com uma tradução humana (DataMListic, a).

A métrica *BLEU* avalia as traduções automáticas através da precisão das seqüências de *n* letras ou palavras, denominadas *n-gramas*. A precisão de *n-gramas* indica a quantidade de *n-gramas* compatíveis entre a sentença a ser avaliada, chamada de sentença candidata, e a sentença de referência equivalente, dividindo este número pelo total de palavras da sentença candidata. Essa compatibilidade deve ser contabilizada apenas uma vez, recebendo o nome de precisão modificada de *n-gramas*. (MELO et al., , p. 04)

Resultandos do Modelo G2P feito em Phonetisaurus

Para usar as métricas *WER*, *CER* e *BLEU* foi usado as seguintes ferramentas de linha de comando *jiwer* para *WER*, *CER* e *sacrebleu* para *BLEU*. Foi usado o esquema discutido anteriormente para treinamento e teste do modelo *G2P*.

Tabela 5 – Resultados obtidos pelos modelos 1 (*train*) e 2 (*train+teste*)

Modelo	WER	CER	BLEU
Modelo 1	0.15	0.08	70.9
Modelo 2	0.11	0.06	79.0

Fonte: Resultados gerados pelas ferramentas *jiwer* e *sacrebleu*, resultados cortados em duas casas decimais sem arredondamento.

Tabela 6 – Transcrição de algumas sentenças aleatórias feitas pelos modelos

Sentença	Modelo 1	Modelo 2
niette é uma amor de pessoa	n i e t t e ε w m m o ɔ d ε p e s o ε	n i e t t e ε w m m o ɔ d ε p e s o a

Sentença	Modelo 1	Modelo 2
winter namelesse wolf	v i t ε ʁ n a m e l e s e v o w f	v i t ε ʁ n a m e l e s e v o w f
mel cepstrum	m e l s ε p i s t r ũ	m e l s ε p i s t r ũ

Fonte: Phonetisaurus ignorar espaços para transcrever sentenças inteiras.

Durante os testes, foi observado que os modelos tenham dificuldades nas vogas como a diferenciação entre e de ε ou a ʁ.

3.1.3.3 Implementação de Phonetisaurus ao Festival

A implementação do software ao *Phonetisaurus* foi feita criando um script na linguagem de programação *Bash Shell* e modificação da função *LTS*, essa função é definida no escopo de definição de léxico. O arquivo modificado é chamado de *INST_pt_VOX_lexicon.scm* sendo as variáveis *INST* para um nome de instituição que está sendo criado a voz ou nome do autor que está criando, *pt* idioma em codificação *ISO 3166-1 alpha-2* e *VOX* para nome da voz dado para construção. A função é chamada *INST_pt_lts_function*, sendo chamado quando a palavra dado ao sintetizador não existe no dicionário local da voz. Usando a função *LTS* com modelo armazenado no diretório *festvox* com arquivos copiados e modificados do caminho da cópia local da ferramenta *Festvox*. A função *LTS* foi rescrita, a função gerará um arquivo temporário servido como cabeçalho com informações como palavra a se transcrita, localização do modelo e arquivo temporário de saída, que será armazenado a transcrição da palavra. Após a geração do cabeçalho, é executando um script em linguagem de programação *Bash Script* servido como argumento a localização do cabeçalho. O script é composto por funções destinadas a normalizar a palavra (converter maiúscula em minúscula), geração da transcrição a partir da execução do *Phonetisaurus* recebendo como parâmetros de entrada a localização do modelo, a palavra, e tratamento da saída do comando utilizando *pipeline* (*|*), e comandos de processamento de texto como *echo*, *sed* e *awk* para obter o resultado desejado. Posteriormente, a palavra e sua transcrição são salvas em um léxico separando do principal na localização */home/\$USER/.local/share/niettetts/dics/niettelabs_pt_addenda.scm*, sendo **USER** o nome do usuário que esteja utilizando, o arquivo *INST_pt_VOX_lexicon.scm* foi modificado para ler o léxico auxiliar e localizar o nome do usuário que esteja executando.

Input: Palavra

Result: Transcrição Fonética da Palavra

begin

Data: MODEL

// Localização do modelo g2p

Data: PALAVRA

Data: ARQUIVOTEMPORARIO

// Arquivo de Cabeçalho

Data: ARQUIVOTEMPORARIO1

// Localização do arquivo contendo a transcrição

Function *Executar script em *Bash Shell* usando a função (*system*) com a localização do cabeçalho como argumento* **is**

| return 0;

end

// Usar função (*system*) para executar comandos

Unix para gerar o cabeçalho em ARQUIVOTEMPORARIO

Function *Ler ARQUIVOTEMPORARIO1* **is**

| return 0;

end

// Ler arquivo contendo a transcrição fonética da

PALAVRA

return *Retornar transcrição ao sintetizador*

end

Algoritmo 1: Versão modificada da função LTS para usar Phonetisaurus através do script feito em linguagem de programação Bash Shell (Resumida)

Input: Localização Cabeçalho

Result: Transcrição Fonética da Palavra no ARQUIVOTEMPORARIO1

```
begin
  Function Ler ARQUIVOTEMPORARIO is
    Data: MODEL
    // Localização do modelo G2P
    Data: PALAVRA
    // Palavra a ser transcrita
  end
  Function Normalizar Palavra is
    // Conversão maiúscula para minúscula
  end
  Function Transcrever Palavra is
    (Phonetisaurus MODEL PALAVRA);
    // Transcrição da Palavra
  end
  Function Escrever TRANSCRIÇÃO em ARQUIVOTEMPORARIO1 is
    // Escrever transcrição da palavra em
    ARQUIVOTEMPORARIO1
  end
  Function Atualizar Dicionário Fonético PALAVRA TRANSCRIÇÃO is
    // Escrever PALAVRA TRANSCRIÇÃO em
    .local/share/niettetts/dics/niettelabsptaddenda.scm
  end
end
```

Algoritmo 2: Script Bash Shell auxiliar da função LTS (Resumida)

3.2 Construção das Vozes

Foram desenvolvidos cerca de 3 vozes para o sintetizador, sendo duas do gênero feminino e uma do gênero masculino.

3.2.1 Corpus usados para as vozes

3.2.1.1 CETUC

O Centro de Estudos em Telecomunicações (*CETUC*), através do Professor Doutor Abraham Alcaim, gentilmente cedeu ao *LaPS*, para fins de pesquisa exclusivamente, seu corpus de áudio para PB. Esse corpus, é composto por áudios de 1.000 sentenças, gravados por 101 locutores, totalizando aproximadamente 143 horas de áudio. (NETO; CRUZ, , p. 38).

Corpus *CETUC* é organizado em pastas, nomeadas com os nomes das pessoas que gravaram os áudios, e com suas informações de gênero e número com áudios na taxa de amostragem de 16Khz. Exemplo: FatimaTurano_F020, FabioCorrea_M032 e AnnaPerez_F046.

3.2.1.2 THLS

Corpus *THLS* (VECCHIETTI,) é composto por áudios de 1.000 sentenças gravadas por um locutor do gênero masculino desenvolvido a partir do documento (CIRIGLIANO et al.,). Totalizando cerca de 1 hora de duração de áudio na taxa de amostragem de 48Khz.

3.2.2 Organização dos Corpus

Foi escolhido duas falantes do corpus *CETUC* para as vozes femininas e uso do corpus *THLS* para criação da voz masculina.

Tabela 7 – Informações sobre nome das vozes e seus corpus que foram usados

Corpus	Nome da Voz
CETUC (ID F050)	Ana
CETUC (ID F000)	Paula
THLS	Pieroni

Fonte: Uso para cada corpus para construção das vozes desse trabalho

3.2.3 Construção de Modelo Vocal

Para construção do modelo vocal da voz é necessário criar a estrutura de diretórios de desenvolvimento da voz, a partir disso foi feito as modificações dos scripts de extração de *MCEP*, *F0* e *STR*. Todos os passos comum para construção de uma voz *Statistical Parametric Synthesis based in HMM* disponível em (BLACK, f) foi feito, mas com modificações propostas por esse trabalho.

3.2.3.1 Extração de F0 usando REAPER

Para fazer a extração da frequência fundamental dos áudios foi necessário limitar o limite máximo e limite mínimo para as vozes desse projeto (COOPER, b). A frequência máxima e mínima se deu usando a seguinte fórmula disponível em (BLACK, d)

Frequência Fundamental Mínima:

$$F0MIN = MEAN - 3 \cdot STD$$

Frequência Fundamental Máxima:

$$F0MAX = MEAN + 3 \cdot STD$$

STD (Standard Deviation) como Desvio Padrão

$$STD = \sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

MEAN é a média de todas as frequência dos áudios

$$MEAN = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$


Para obter as frequências fundamentais iniciais, o range foi definido como 400Hz para F0MAX e 50Hz para F0MIN.

Tabela 8 – Resultados obtidos para *F0MAX* e *F0MIN* das vozes Ana, Paula e Pieroni

Nome	F0MAX	F0MIN	STD	MEAN
Ana	34Hz	89Hz	43Hz	218Hz
Paula	378Hz	103HZ	45Hz	240HZ
Pieroni	224Hz	57Hz	27Hz	141Hz

Fonte: Resultados de F0MAX, F0MIN, STD e MEAN obtidos usando script em linguagem Bash Shell *bin/find_f0_stats* modificado para usar REAPER com range de 50Hz a 400hz.

Figura 1 – Comparação entre REAPER e SPTK (algoritmo padrão) para extração de F0



Fonte: F0 extraído de um dos áudios na taxa de amostragem em 16Khz do corpus da voz Pieroni. Foi usando os valores F0MIN e F0MAX da voz Pieroni para extração.

Uso do *REAPER* mostrou-se suavidade em comparação com *SPTK*, menor sensibilidade em área *unvoiced* sem mudanças bruscas. *SPTK*, mostrou-se agressividade em áreas de *unvoiced* e de silêncio, fazendo essas mesmas áreas com *F0* altos.

3.2.3.2 Extração de MCEP

Para extração de *MCEP* é necessário transformar e fazer processamento no arquivo de forma de onda e parâmetros de extração podem mudar conforme a taxa de amostragem. O processo de extração de *MCEP* consiste em:

- 1) Transformar o arquivo de forma de onda no tipo *RAW*;
- 2) Transformar o arquivo de forma de onda convertido em *RAW* para *SHORT* para ser processados pela ferramenta *SPTK-4*;
- 3) Usar *Short-Time Fourier* para análise do sinal;
- 4) Após a análise, extração de segmentos por meio de *Windowing*;
- 5) Extração de *MCEP* usando escala de mel.

Fontes: (BäCKSTRÖM et al.,) e (McFee,)

Nas etapas 3 a 5 é necessário definir os valores de *Frame Shift* deslocamento entre os frames, *Frame Length* para quantidade de amostras por frame. Os valores mudam de acordo a taxa de amostragem da forma de onda, comumente esses valores são definidos como.

Frame Shift:

$$0.005 \cdot f_s$$

Frame Length:

$$0.025 \cdot f_s$$

Sendo f_s , representado taxa de amostragem em Hz.

Exemplo para a taxa de amostragem de 16Khz.

$$16Khz = 16000$$

$$FrameShift = 0.005 \cdot 16000 = 80$$

$$FrameLength = 0.025 \cdot 16000 = 400$$

Observação sobre NFFT

Existe um valor essencial para extração é longitude do frame representado como *NFFT* sendo escalonável por potência de dois como, 512, 1028 e 2048. Maior esse valor maior a percepção de frequências pequeno, mas com maior custo de processamento (SHKHANUKOVA,). Nesse trabalho foi definido *NFFT* como 4096.

A extração *MCEP* além de definir os valores acima, é necessário definir a número de order do *mcep* M que define como é moldado e α (*frequency warping*, deformação de frequência)

¹ estimada por uma função de filtro passa-tudo.

¹ Houver diferenciação ao pesquisa o termo no português, sendo em tradução literal como distorção de frequência tendo referencia como distorção harmônica. Mas, em processamento de sinais ou áudio foi encontrado como transformada de warped.

Convencionalmente, os valores para M são fixos para 25 ou 35 e α , são definidos como:

Tabela 9 – Valores de α para cada taxa amostragem em Khz

f_s	Alpha (α)
8	0.31
10	0.35
12	0.37
16	0.42
22.05	0.45
32	0.50
44.1	0.53
48	0.55

Fonte: (MGCEP...,)

Nesse trabalho, visando aumentar a similitude e a qualidade da síntese, foi usado como referência o artigo (YAMAGISHI; KING, 2010) para novos valores para M e α . Para calcular os valores de α usado as escalas de *Bark* e *ERB*:

Escala Bark:

$$\alpha_{Bark} = 0.8517 * \sqrt{\arctan 0.06583 \cdot f_s} - 0.1916$$

Escala ERB:

$$\alpha_{ERB} = 0.5941 * \sqrt{\arctan 0.1418 \cdot f_s} + 0.03237$$

Calculando os valores de α para seguintes taxas de amostragem das vozes:

Tabela 10 – Valores de M e α para as taxas de amostragem usadas nesse trabalho

f_s	M	α	Escala
16Khz	49	0.42	Mel
48Khz	68	0.741547	ERB

Fonte: Calculados usando comando bc e arredondamento feito pelo comando x2x do SPTK. Não existe menção de M para f_s 48Khz, foi usando o valor de M para 48Khz.

3.2.3.3 Extração de STR (Voicing Strengths)

Como a síntese usando a técnica de *Statistical Parametric Synthesis based in HMM*, baseasse na geração de *MCEP* e *F0*. As ondas sonoras são geradas a partir da excitação de frequências produzidos pelos modelos *HMM*, uma forma de aumentar a qualidade da síntese é usar uma excitação mista, reduzindo a sensação de zumbido ou ruídos na fala sintetizada. A excitação mista, a sua definição e sua implementação a síntese *HMM* no artigo: (YOSHIMURA et al., 2001).

Para extração de *STR*, o projeto *Festvox* usar a versão antiga da ferramenta *SPTK* sendo a *SPTK-3.6* sendo um *patch* no comando de extração de *F0* chamado de *pitch*. Com a atualização do *SPTK-3.6* para *SPTK-4* ao projeto *Festvox*, foi feito uma busca de uma alternativa para extração de *STR* para excitação mista foi encontrado o projeto de sintetizador feito em linguagem programação *Java* que usar o projeto *HTS* para gerar a síntese usado as técnicas de *Unit Selection* e *Statistical Parametric Synthesis based in HMM* chamado de *MaryTTS* (MARYTTS/MARYTTS, 2025).

O projeto *MaryTTS*, existem scripts para extração de *F0*, *MCEP* e *STR* para treinamento de modelos para síntese *HMM*. Usasse a biblioteca *Snack* (Scotty, 2025) na linguagem de programação *TCL*, bastante usada na criação de scripts para automação mediante de um script auxiliar feito em linguagem *Bash Shell* e outro em linguagem *TCL* com arquivos de filtros para cada taxa de amostragem e parâmetros de *frame length* e de *F0MAX* e *F0MIN* como argumentos. Com isso, foi feito a adaptação para funcionar com projeto *Festvox* com os argumentos de *F0MAX* e *F0MIN* retirados da etapa de extração de *F0*.

3.2.3.4 Combinação de *F0*, *MCEP*, *STR* em *ccoefs*.

Após as etapas de alinhamento temporal fonético, extração de *F0*, *MCEP*, *STR* e outros arquivos gerados pelo projeto *Festvox* para construção do modelo vocal esses arquivos são unificados e combinados em um só arquivo chamado de *ccoefs*. Os *ccoefs* contém ambas as informações acústicas, linguísticas e prosódicas para treinamento dos modelos para predição de *F0* e *MCEP* (*MCEP+STR*) para serem passadas ao *vocoder*, para treinamento é feito um pré-processamento para separar os *ccoefs* em dados para cada unidade/estados dos fonemas.

Esse processo no *Festvox* tem algumas falhas relatado nos comentários no script que faz esse processo, a causa não foi comentada. Como o conjunto de fala é pequeno, qualquer perca prejudique a qualidade da síntese, pois haverá dados insuficientes para treinamento de alguns fonemas que tenham poucas aparições no conjunto de fala. Foi feito uma rescrita desse script para mendigar ou evitar essas falhas de perda de dados, e adição de processamento *parallel* para processar e criar os dados para cada fonema de forma simultânea conforme a quantidade de núcleos do processador usando o comando chamado *parallel* (TANGE, 2024).

3.2.4 Mensuração de Modelos

Após a construção dos modelos vocais é necessário mensurar sua qualidade de síntese e sua similitude com falante original. Existem técnicas focadas em atribuições de notas feitas por ouvintes para cada aspectos da fala sintetizada, como qualidade, similitude e pronúncia das palavras.

3.2.4.1 Escala MCD

Comumente usasse a métrica *MCD*, que mensurar a diferença entre duas sequências de dois arquivos mel cepstral (COOPER, a). Comparação o alvo (fala sintetizada) com o alvo (falante original), usado DTW (Wikipedia contributors, 2025) para medir sua similaridade.

Em sistemas *TTS* pretende mensurar o quão próximo é a fala sintetizada com a fala original do falante, números próximo a 0 mostram que a fala sintetizada tem melhor similaridade com falante original (WILDERNESS... ,). No *Festvox*, tem scripts para essa mensuração.

Tabela 11 – Valores *MCD* para cada voz desenvolvida nesse projeto

Voz	MCD
Ana	3.80
Paula	3.90
Pieroni	5.92

Fonte: Cálculos da métrica *MCD* para cada voz desenvolvida nesse projeto usando scripts do projeto *Festvox*.

O *MCD* da Pieroni foi muito alto em referência a outras vozes, significando uma grande diferença do falante original. O motivo desse *MCD* é incerto, pode-se ter ocorrido devido a extração de *MCEP*, a escolha do α e do *MCEP Order* para taxa de amostragem 48Khz não foi apropriado.

Foi refeito a voz Pieroni com a taxa de amostragem de 44Khz que existem números de α e *MCEP Order* apropriados. *MCD* gerado foi 3.70, devido ao tempo e normalização foi mantido o uso da taxa de amostragem de 48Khz.

3.2.4.2 Escala MOS

É uma escala subjetiva que consiste na medida numérica baseada na opinião pessoal de ouvintes (CASELI; NUNES, , p. 42). É feito a atribuição de pontuações de uma escala de 1 a 5 referente a qualidade da síntese, como 5 indicado que o resultado foi “excelente”, 1 indicado que o resultado foi “ruim” e o restante á resultados entre os dois mencionados. A partir da etapa de atribuição é feito a média dessas pontuações, a média resultante é escala *MOS* (Philipos C. Loizou, , p. 626).

Em (Philipos C. Loizou, , p. 627), é mencionado ITU-R BS.562-3 que incluir praticas recomendáveis para métodos de mensuração subjetiva de qualidade de sons que atribuir algumas recomendações para fazer os métodos de mensuração como:

- 1) Escolha de ouvintes: Diferenças de números de ouvintes dependerá que eles tenham alguma ou nenhuma experiencia em mensuração de qualidade de som ou mesmo experiencia envolvendo a sons. Recomendam mínimo de 20 ouvintes que não tenha nenhuma

experiencia com sons e mínimo de 10 ouvintes que tenha alguma experiencia envolvendo sons;

- 2) Teste e duração: Os audios originais e sintetizados devem está em ordem aleatória como duração do teste de máximo de 20 minutos sem interrupção. Isso é necessário para pode evitar fadiga sonora;
- 3) Uso de headphones ou fone de ouvido são recomendáveis para evitar qualquer alteração acústica feita pelo auto-falante, sala ou qualquer sistema de som.

Foi usando a abordagem (CASELI; NUNES, , p. 42), para mensuração *MOS* que consiste apenas em atribuições para áudio sintetizados dos modelos feitos nesse trabalho. Devido a falta de ouvintes para fazer a mensuração, não haverá os resultandos da escala *MOS* para as vozes desenvolvidas nesse trabalho.

3.3 Implementação em Speech-Dispatcher

Speech-Dispatcher, é uma *API* usada em sistemas operacionais *Linux* que necessitam usar recursos de síntese de fala de uma maneira que não envolver a configurações extras (BRILCOM/SPEECHD, 2025). Sendo responsável por fornecer as funções de síntese de fala em leitores de telas *Linux* e aplicativos de leitores de documentos que utilizam a função de *Text-to-Speech* como *Okular* do projeto *KDE* (KDE/OKULAR, 2025). *Speech-Dispatcher* é constituído por módulos, esses módulos são responsáveis por integrar e fornecer configurações para cada motor de síntese de fala disponíveis. A configuração padrão do *Speech-Dispatcher* é uso do sintetizador de fala *ESpeak*, sendo o mesmo instalado por padrão. Mas, sendo possível refazer a sua configuração para suporta outros sintetizadores, ativando os seus módulos responsáveis pela integração e configurações deles mesmo. Ativação da integração do *Festival Speech Synthesis System* ao *Speech-Dispatcher* para ser possível a utilizam fora do ambiente *Festival CLI* necessitar a instalação do módulo de *Speech-Dispatcher* para *Festival* (*speech-dispatcher-festival*) e uma extensão com algumas modificação para *Festival* melhorar o suporte. A extensão com nome *festival-freebsoft-utils*, oferecer algumas modificações ao *Festival*, como suporte da listagem de idiomas instalados para melhor integração, modos de leitura de pontuações, *SSML* mais robusto e outras melhorias listadas em (BRILCOM/FESTIVAL-FREEBISOFT-UTILS, 2024).

3.3.1 Modificação da extensão

A função de listagem de vozes instalada na extensão é responsável por retornar as vozes instalada e suas respectivas informações. Essa função feita em *Lisp* sendo uma lista com pares de chaves, util para adicionar vários do mesmo tipo com uma buscar de um valor (chave) com seu equivalente (*ASSOCIATION*... ,). As entrada dessa função são definições de informações sobre a voz, como idioma, seu dialeto, gênero, idade e sua descrição no arquivo de definições contido nos arquivos de voz. As informações essenciais são idioma e dialeto, para esse trabalho

foi utilizando as informações referentes ao idioma, seu dialeto e gênero das vozes. A função por padrão não reconhecer e não retornar o idioma português e seus dialetos como português europeu e brasileiro, com isso foi feita a modificação disponível em (Pallas13; brailcom,). As requisições feitas pelo *Speech-Dispatcher* contêm essencialmente informações sobre a voz e texto escolhido, com algumas outras informações como velocidade, pitch e entre outras. Há pequenas diferenças caso ocorra a utilização do Festival *TTS*, sendo a função em que *Speech-Dispatcher* faz uma requisição de síntese de uma palavra pré-definida para verificação tendo sua resposta nula e por fim uma normalização do texto escolhido para conversão da sua codificação original (UTF-8) para ISO-8889-1.

Foi feita modificação dessas funções para que o processo de integração entre *Speech-Dispatcher* e *Festival TTS* com as novas vozes desenvolvidas nesse trabalho ocorra corretamente. A modificação removeu a função que executar a requisição de verificação e modificação na função de conversão de codificação que é ignorada quando á uma variável de valor booleano é definida como verdadeiro, essa variável é definida nos arquivos das vozes. A modificação está disponível em (Pallas13, a).

4 Considerações Finais

Nessa monografia foi possível a construção de um sintetizador texto para fala em português brasileiro para hardwares que operam e utilizam sistemas operacionais *Linux* como *Desktop* e *embarcado*. Utilizando síntese de fala baseado em modelos ocultos de Markov, introduzido diversos conceitos utilizado em processamento de fala e descrições das etapas de desenvolvimento do sintetizador de fala. Foi utilizado sintetizador de fala *Festival Speech Synthesis System*, para desenvolvimento do sintetizador *NietteTTS* desenvolvendo diversos recursos para tornar a síntese a melhor possível.

Referências

AdolfVonKleist. *Phonetisaurus*. Disponível em: <<https://github.com/AdolfVonKleist/Phonetisaurus>>. Citado na página 21.

ASSOCIATION Lists (MIT/GNU Scheme 12.1). Disponível em: <<https://www.gnu.org/software/mit-scheme/documentation/stable/mit-scheme-ref/Association-Lists.html>>. Citado na página 36.

BLACK, A. W. *Festival Speech Synthesis System: 12. phonesets*. Disponível em: <http://www.festvox.org/docs/manual-2.4.0/festival_12.html>. Citado 2 vezes nas páginas 23 e 24.

BLACK, A. W. *Festival Speech Synthesis System - 13 Lexicons*. Disponível em: <http://www.festvox.org/docs/manual-1.4.3/festival_13.html#SEC43>. Citado na página 24.

BLACK, A. W. *Festvox*. Disponível em: <<http://festvox.org/>>. Citado na página 21.

BLACK, A. W. *festvox/src/intonation/find_f0_stats*. Disponível em: <>. Citado na página 30.

BLACK, A. W. *Machine Learning in Speech Synthesis*. Disponível em: <<https://www.cs.cmu.edu/~bhiksha/courses/mlsp.fall2009/class10/black.slides.pdf>>. Citado 2 vezes nas páginas 19 e 24.

BLACK, A. W. *Statistical Parametric Synthesis*. Disponível em: <<http://festvox.org/bsv/c3174.html>>. Citado na página 30.

BONFIM, A. *Entenda o que é Linux da forma mais fácil!* Section: Vídeo. Disponível em: <<https://diolinux.com.br/video/o-que-e-linux-da-forma-mais-facil.html>>. Citado na página 16.

BRAILCOM/FESTIVAL-FREEBISOFT-UTILS. BRAILCOM,o.p.s., 2024. Original-date: 2019-02-19T17:39:23Z. Disponível em: <<https://github.com/brailcom/festival-freebsoft-utils>>. Citado na página 36.

BRAILCOM/SPEECHD. BRAILCOM,o.p.s., 2025. Original-date: 2017-11-20T12:52:14Z. Disponível em: <<https://github.com/brailcom/speechd>>. Citado na página 36.

BÄCKSTRÖM, T. et al. *Introduction to Speech Processing*. 2. ed. [s.n.]. Disponível em: <<https://speechprocessingbook.aalto.fi>>. Citado 2 vezes nas páginas 20 e 32.

CASELI, H. M.; NUNES, M. G. V. (Ed.). *Processamento de Linguagem Natural: Conceitos, técnicas e aplicações em português*. BPLN. Disponível em: <<https://brasileiraspln.com/livro-pln/3a-edicao/>>. Citado 3 vezes nas páginas 17, 35 e 36.

CIRIGLIANO, R. et al. Um conjunto de 1000 frases foneticamente balanceadas para o português brasileiro obtido utilizando a abordagem de algoritmos genéticos. In: . [s.n.]. Disponível em: <<https://biblioteca.sbrt.org.br/articles/3223>>. Citado na página 30.

COOPER, E. *MCD*. Disponível em: <<https://www.cs.columbia.edu/~ecooper/tts/mcd.html>>. Citado na página 35.

COOPER, E. *Tuning F0 Extraction Ranges*. Disponível em: <<https://www.cs.columbia.edu/~ecooper/tts/f0extract.html>>. Citado na página 30.

CUNHA, C.; CINTRA, L. *Nova Gramática Do Português Contemporâneo - Conforme Nova Ortografia*. [S.l.]: Lexikon, 2008. ISBN 9788586368486. Citado 2 vezes nas páginas 16 e 24.

DANIJEL, K. *Phonetisaurus*. Disponível em: <<https://github.com/danijel3/Phonetisaurus>>. Citado na página 22.

DataMListic. *BLEU Score Explained*. Disponível em: <<https://www.youtube.com/watch?v=25kutmqou6o>>. Citado na página 26.

DataMListic. *Word Error Rate (WER) Explained - Measuring the performance of speech recognition systems*. Disponível em: <<https://www.youtube.com/watch?v=hoEWRdHi7dI>>. Citado 2 vezes nas páginas 25 e 26.

FESTIVAL. Disponível em: <<https://www.cstr.ed.ac.uk/projects/festival/>>. Citado na página 21.

JURAFSKY, D.; MARTIN, J. H. *Speech and Language Processing: An introduction to natural language processing, computational linguistics, and speech recognition, with language models*. 3rd. ed. [s.n.]. Disponível em: <<https://web.stanford.edu/~jurafsky/slp3/>>. Citado 2 vezes nas páginas 16 e 17.

KDE/OKULAR. KDE GitHub Mirror, 2025. Original-date: 2015-09-18T15:43:52Z. Disponível em: <<https://github.com/KDE/okular>>. Citado na página 36.

KERNEL Linux | O que é o Kernel Linux? Disponível em: <<https://www.redhat.com/pt-br/topics/linux/what-is-the-linux-kernel>>. Citado na página 16.

LEE, J. L. et al. Massively multilingual pronunciation modeling with WikiPron. In: CALZOLARI, N. et al. (Ed.). *Proceedings of the Twelfth Language Resources and Evaluation Conference*. European Language Resources Association. p. 4223–4228. ISBN 979-10-95546-34-4. Disponível em: <<https://aclanthology.org/2020.lrec-1.521/>>. Citado na página 23.

MARYTTS/MARYTTS. marytts, 2025. Original-date: 2011-12-20T16:44:48Z. Disponível em: <<https://github.com/marytts/marytts>>. Citado na página 34.

McFee, B. *Digital Signals Theory*. [s.n.]. Disponível em: <<https://brianmcfee.net/dstbook-site/>>. Citado na página 32.

MELO, F. et al. e-escrita APLICAÇÃO DA MÉTRICA BLEU PARA AVALIAÇÃO COMPARATIVA DOS TRADUTORES AUTOMÁTICOS BING TRADUTOR e GOOGLE TRADUTOR APPLICATION OF THE BLEU SCORES TO COMPARATIVE EVALUATION OF AUTOMATIC TRANSLATORS BING AND GOOGLE TRANSLATOR. Citado na página 26.

MGCEP SPTK documentation. Disponível em: <<https://sp-nitech.github.io/sptk/latest/main/mgcep.html>>. Citado na página 33.

NETO, S.; CRUZ, N. Ferramentas e recursos livres para reconhecimento e síntese de voz em português brasileiro. Disponível em: <<https://repositorio.ufpa.br/items/99c199f3-f41d-4fa5-a4d9-2f10a449>>. Citado na página 29.

Pallas13. *NietteLabs/festival-freebsoft-utils*. NietteLabs. Original-date: 2025-07-09T20:21:05Z. Disponível em: <<https://github.com/NietteLabs/festival-freebsoft-utils>>. Citado na página 37.

Pallas13. *NietteTTS/vox_files/pt/INST_pt_VOX_phoneset.scm at main · NietteLabs/NietteTTS*. Disponível em: <https://github.com/NietteLabs/NietteTTS/blob/main/vox_files/pt/INST_pt_VOX_phoneset.scm>. Citado na página 24.

Pallas13. *Phonetisaurus*. NietteLabs. Disponível em: <<https://github.com/NietteLabs/Phonetisaurus>>. Citado na página 22.

Pallas13; brailcom. *Add pt language to festival-freebsoft-utils@39cf0da*. Disponível em: <<https://github.com/brailcom/festival-freebsoft-utils/commit/39cf0da189b2e559d61f398b60b8c169160f263f>>. Citado na página 37.

Philipos C. Loizou. *Speech Quality Assessment*. [s.n.]. Disponível em: <https://ecs.utdallas.edu/loizou/cimplants/quality_assessment_chapter.pdf>. Citado na página 35.

Rita-ritally. *No pronunciation for word: (ALL!) #72*. Disponível em: <<https://github.com/AdolfVonKleist/Phonetisaurus/issues/72>>. Citado na página 22.

Scotty. *scottypitcher/tcl-snack*. 2025. Original-date: 2021-10-31T04:22:43Z. Disponível em: <<https://github.com/scottypitcher/tcl-snack>>. Citado na página 34.

SHKHANUKOVA, M. *Choose N_FFT for Spectrograms, FFT*. Disponível em: <<https://medium.com/@milana.shxanukova15/n-fft-parameter-in-fft-134712e1c79d>>. Citado na página 32.

SOUZA, C. Francisco Soares de. *Síntese de fala em português brasileiro baseada em modelos ocultos de Markov*. phdthesis. Disponível em: <<https://repositorio.ufpe.br/handle/123456789/2267>>. Citado na página 18.

TALKIN, D. *REAPER*. Google. Disponível em: <<https://github.com/google/REAPER>>. Citado na página 21.

TANGE, O. *GNU Parallel 20240222* (''). Zenodo, 2024. Disponível em: <<https://doi.org/10.5281/zenodo.10719803>>. Citado na página 34.

VECCHIETTI, L. F. *THLS - An open source dataset for Brazilian Portuguese speech processing*. Disponível em: <<https://gitlab.com/lfelipesv/1000-sentences-thls-dataset>>. Citado na página 30.

Wikipedia contributors. *Dynamic time warping* — *Wikipedia, The Free Encyclopedia*. 2025. [Online; accessed 17-November-2025]. Disponível em: <https://en.wikipedia.org/w/index.php?title=Dynamic_time_warping&oldid=1318161628>. Citado na página 35.

WIKIPRON/DATA/SCRAPE/TSV/POR_LATN_BZ_BROAD_FILTERED.TSV at master • CUNY-CL/wikipron. Disponível em: <https://github.com/CUNY-CL/wikipron/blob/master/data/scrape/tsv/por_latn_bz_broad_filtered.tsv>. Citado na página 23.

WIKIPRON/DATA/SCRAPE/TSV/POR_LATN_PO_BROAD_FILTERED.TSV at master • CUNY-CL/wikipron. Disponível em: <https://github.com/CUNY-CL/wikipron/blob/master/data/scrape/tsv/por_latn_po_broad_filtered.tsv>. Citado na página 23.

WILDERNESS Multilingual Speech Dataset. Disponível em: <http://festvox.org/cmu_wilderness/>. Citado na página 35.

YAMAGISHI, J.; KING, S. Simple methods for improving speaker-similarity of HMM-based speech synthesis. In: . [s.n.], 2010. Disponível em: <<https://era.ed.ac.uk/handle/1842/4544>>. Citado na página 33.

YOSHIMURA, T. et al. SPTK4: An open-source software toolkit for speech signal processing. In: *12th ISCA Speech Synthesis Workshop (SSW 2023)*. [S.l.: s.n.]. p. 211–217. Citado na página 21.

YOSHIMURA, T. et al. Mixed excitation for hmm-based speech synthesis. In: *7th European Conference on Speech Communication and Technology (Eurospeech 2001)*. [S.l.: s.n.], 2001. p. 2263–2266. ISSN 1018-4074. Citado na página 33.